Projet Graph Analytics

Réalisé par:

LABIAD Soukaina

PLAN

- 1. Introduction
- 2. Préparation de la base de données
- 3. Le voyageur du Monde
- 4. Les interconnectés

Introduction

- Analyser le trafic aérien.
- Résoudre des problèmes.
- Proposer des solutions.

Le jeu de données est extrait du site : https://openflights.org/data.html

Préparation de la base de données Le jeu de données

5 fichiers .csv:



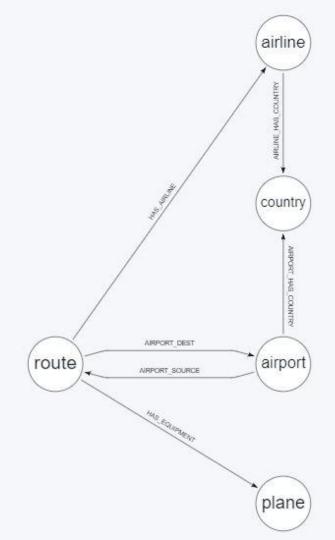
- les aéroports
- les compagnies aériennes
- les routes aériennes
- les informations sur les pays
- les informations sur les avions

Nettoyage et Indexation des données

L'indexation rend les recherches de données plus rapides et efficaces.

:schema						
Index Name	Туре	Uniqueness	EntityType	LabelsOrTypes	Properties	State
constraint_2619603d	BTREE	UNIQUE	NODE	["route"]	["Route ID"]	ONLINE
constraint_359b776	BTREE	UNIQUE	NODE	["airline"]	["Airline ID"]	ONLINE
constraint_c218edec	BTREE	UNIQUE	NODE	["country"]	["Name"]	ONLINE
constraint_c5e0a97	BTREE	UNIQUE	NODE	["airport"]	["AirportID"]	ONLINE
constraint_f28b0e99	BTREE	UNIQUE	NODE	["plane"]	["Name"]	ONLINE
index_343aff4e	LOOKUP	NONUNIQUE	NODE			ONLINI
index_f7700477	LOOKUP	NONUNIQUE	RELATIONSHIP			ONLINE

- Créer une instance de base de données avec neo4j auroraDB.
- Importer les données dans la base.
- 3. Modéliser la base de données graphe.



Balayage des données

Pour bien comprendre le jeu de données et les relations entre les noeuds, nous avons essayé à répondre à quelques questions:

Balayage des données

Quels sont les aéroports français?

Requête:

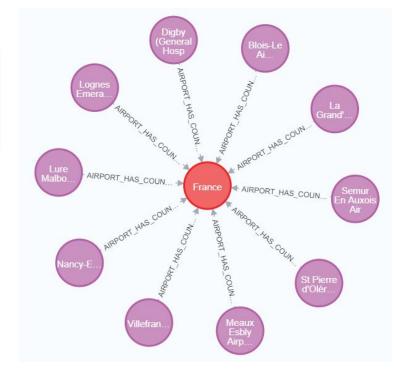
```
neo4j$ MATCH (n1:airport)-

[r:AIRPORT_HAS_COUNTRY]→

(n2:country{Name:'France'})

RETURN r, n1, n2 LIMIT 10
```

Résultat:

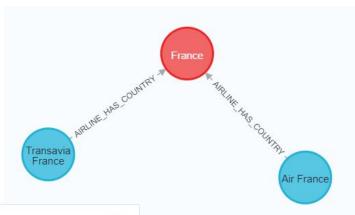


Balayage des données

Quelles sont les compagnies aériennes

françaises actives?

Résultat:



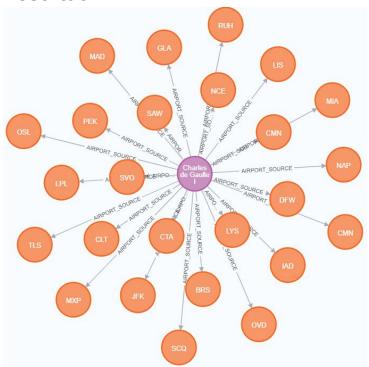
Requête:

Balayage des données

Quelles sont les lignes au départ de l'aéroport Charles de Gaulle (CDC) ? **Requête**:

```
MATCH (n1:airport{AirportID:'1382'})-
[r:AIRPORT_SOURCE]→(n2:route) RETURN r,
n1, n2 LIMIT 25
```

Résultat:

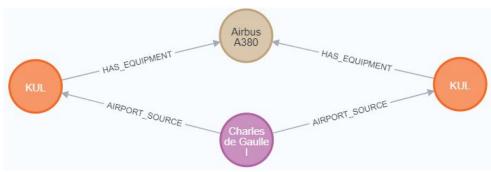


Balayage des données

Quelles sont les lignes au départ de l'aéroport CDC délivrées par un A380 ?

Requête:

Résultat:

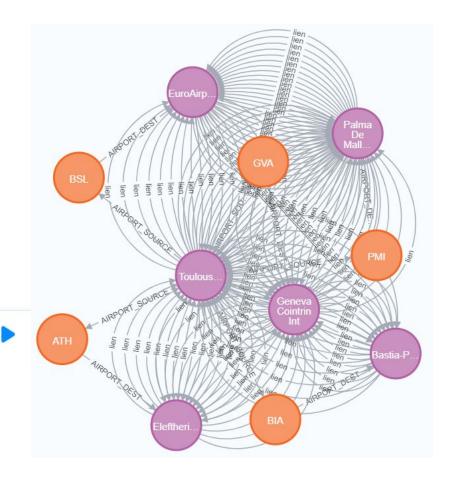


```
neo4j$ MATCH (n1:airport{AirportID:'1382'})-
[r:AIRPORT_SOURCE]→(n2:route)-
[r2:HAS_EQUIPMENT]→(n3:plane{Name:"Airbus
A380"}) RETURN r, n1, n2 LIMIT 25
```

L'aéroport de départ est **Toulouse-Blagnac Airport** → le plus proche à TOURNEFEUILLE.

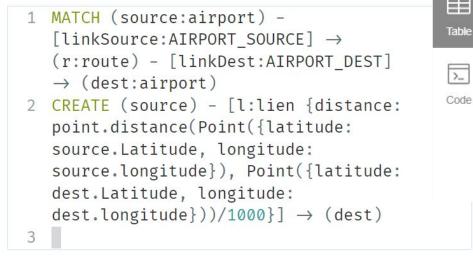
La requête Cypher utilisée:

```
1 MATCH (a1:airport {Name:
    'Toulouse-Blagnac Airport'})-
    [rel1:AIRPORT_SOURCE]→(r:route)-
    [rel2:AIRPORT_DEST]→(a2:airport)
2 RETURN a1,rel1,r,rel2,a2 LIMIT 5
```



On avait besoin d'ajouter la propriété **distance** comme coût de la relation entre les aéroports de départ et d'arrivée.

La requête Cypher utilisée:



Created 38131 relationships, completed after 215 ms.

囯

>_

Code

Puis on a stocké notre graphe sous le nom

voyageurMonde, qui contient tous les aéroports

de l'Europe en noeuds et la distance entre eux

sur les arêtes.

La requête Cypher utilisée:

```
1 CALL gds.graph.project(
2   'voyageurMonde',
3   'airport',
4   {lien: {orientation: 'NA1   'distance'}}
5 )
```

```
graphName
                                                        nodeCount
                                                                      relationshipCount
                             The same
                                     "vovageurMonde"
                                                        7698
                                                                      305048
  "lien": {
"orientation": "NATURAL",
"aggregation": "DEFAULT",
"type": "lien",
"properties": {
"distance": {
"defaultValue": null,
"property": "distance",
"aggregation": "DEFAULT"
```

Choix d'algorithme: All Pairs Shortest Path

- Trouve le chemin le plus court entre toutes les paires de nœuds.
- Se base sur un graph pondéré.

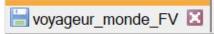
Résultat:

 Matrice des distances minimales entre chaque nœud et tous les autres nœuds du graphs.

```
1 CALL gds.alpha.allShortestPaths.stream('voyageurMonde', {
2    relationshipWeightProperty: 'distance'
3  })
4 YIELD sourceNodeId, targetNodeId, distance
5 WITH sourceNodeId, targetNodeId, distance
6 WHERE gds.util.isFinite(distance) = true
7
8 MATCH (source:airport) WHERE id(source) = sourceNodeId
9 MATCH (target:airport) WHERE id(target) = targetNodeId
10 WITH source, target, distance WHERE source <> target
11 RETURN source.Name AS source, target.Name AS target, distance
12 ORDER BY distance ASC LIMIT 10
```

Résultat:

Fichier .csv qui contient les distances entre les différents aéroports de l'Europe dans un ordre ascendant.



- 1 source, target, distance
- 2 Lanzarote Airport, Fuerteventura Airport, 60.39055141525801
- 3 Saarbrücken Airport, Luxembourg-Findel International Airport, 79.785658362836
- 4 Luxembourg-Findel International Airport, Saarbrücken Airport, 79.785658362836
- 5 Aarhus Airport, Aalborg Airport, 100.00687717907952
- 6 Aalborg Airport, Aarhus Airport, 100.00687717907952
- 7 Helsinki Vantaa Airport, Lennart Meri Tallinn Airport, 100.88566230018043
- 8 Lennart Meri Tallinn Airport, Helsinki Vantaa Airport, 100.88566230018043
- 9 Lycksele Airport, Arvidsjaur Airport, 118.99224664597621

Exploitation du résultat pour répondre au besoin:

→ Algorithm Dijkstra pour trouver le plus court chemin en connaissant l'aéroport source et l'aéroport target.

```
def start_process(start_airport, target_airport):
    nodes, init_graph = generate_graph_from_csv()
    graph = Graph(nodes, init_graph)

Voyageur du Monde Start !

Toulouse-Blagnac Airport -> Hamburg Airport -> Halmstad Airport
2580.9032110587505

Halmstad Airport -> Växjö Kronoberg Airport -> Il Caravaggio International Airport -> Košice Airport
3062.8490264636825

Košice Airport -> Il Caravaggio International Airport -> Toulouse-Blagnac Airport
1988.0184455594317

start_process("Halmstad Airport", "Košice Airport")
start_process("Košice Airport", "Toulouse-Blagnac Airport")
```

Visiter 6 villes

Distance totale = 7 630 Km

```
Voyageur du Monde Start !
Toulouse-Blagnac Airport -> Hamburg Airport -> Halmstad Airport
2580.9032110587505
Halmstad Airport -> Växjö Kronoberg Airport -> Il Caravaggio International Airport -> Košice Airport
3062.8490264636825
Košice Airport -> Il Caravaggio International Airport -> Toulouse-Blagnac Airport
1988.0184455594317
```

Fonction de visualisation de l'aéroport sur la carte en utilisant Folium

```
v def show_me_my_airport(my_airport):
      loc = return_location(my_airport)
      map = folium.Map(location=loc)
      map.save(my airport+".html")
v def return_location(airport_name):
      location = []
      airport = airports_df[airports_df['Name'] == airport_name]
      lat = airport.iloc[0]['Latitude']
      long = airport.iloc[0]['Longitude']
      location.append(lat)
      location.append(long)
      return location
  show_me_my_airport("Toulouse-Blagnac Airport")
```



Demo

Les interconnectés

Les interconnectés

La distance minimale entre deux aéroports est de 150 km.

à partir d'un fichier ordonné par distance entre aéroports ascendants, on déduit les aéroports à supprimer.

NoteBook:

http://localhost:8888/notebooks/Documents/GraphAnalytics/5_les%20interconnect%C3% A9s.ipynb

23 aéroports

Résultat^a

- Lanzarote Airport
- Saarbrücken Airport
- Luxembourg-Findel International Airport
- Aarhus Airport
- Aalborg Airport
- Helsinki Vantaa Airport
- Lennart Meri Tallinn Airport
- Arvidsjaur Airport
- Lycksele Airport
- Halmstad Airport
- Poitiers-Biard Airport
- La Rochelle-Île de Ré Airport
- Palma De Mallorca Airport
- Menorca Airport
- Munich Airport
- Nuremberg Airport
- Ibiza Airport
- Tampere-Pirkkala Airport
- Ivalo Airport
- Copenhagen Kastrup Airport
- Fuerteventura Airport
- Växjö Kronoberg Airport
- Kittilä Airport

Demo

Merci pour votre attention